

api-doctor

깨진 공공 API 연동 코드를 고치고,
그게 진짜 고쳐졌는지 LLM 없이 검증하는 에이전트

LLM은 어디를 볼지만 정합니다.
무엇이 참인지는 LLM이 없는 코드가 정합니다.

프로젝트 리포지토리

<https://github.com/HyeonsangKim/api-doctor>

아키텍처 브리핑 (도면 4종과 전체 해설)

<https://claude.ai/artifact/H1eVwpVD1CJkgF2YSQDtKQ>

18/18

결함 탐지
거짓 성공 0건

5/5

격리 경계
자가검사 차단

183

테스트
전부 통과

0

에이전트가 달는
검증기·정답

모델 nvidia/nemotron-3-super-120b-a12b (reasoning)
폴백 nvidia/nemotron-3-nano-omni-30b-a3b-reasoning
엔드포인트 NVIDIA NIM · integrate.api.nvidia.com/v1 · 무료 등급
하네스 deepagents 0.7.19 · LangChain · LangGraph
격리 Docker (network none, read-only, cap-drop ALL)
측정 기준일 2026-09-28

1. 해결하려는 문제

공공데이터 API를 붙여본 사람은 이 상황을 압니다.

```
200 OK
종료 코드 0
예외 없음
그런데 데이터가 이상하다
```

페이지 경계에서 레코드가 새고, 필드가 조용히 비고, 요청한 범위와 받은 범위가 어긋납니다. 에러가 없으니 스택트레이스도 없고 어디를 봐야 할지 단서가 없습니다. 결국 응답을 눈으로 훑으며 며칠을 씁니다.

여기에 LLM을 붙이면 문제가 더 커집니다. 모델이 "고쳤습니다"라고 말하는 순간 그 말이 곧 결론이 되기 때문입니다. **고친 쪽이 채점까지 하는 구조에서는 틀린 수리가 통과합니다.**

그래서 판정 권한을 모델에게서 완전히 뺐습니다

고정 검증기는 네 가지를 봅니다. 실행, 필드, 값, 전체성입니다. 앞의 셋이 전부 통과해도 전체성 검사가 잡아냅니다. 이 판정에 LLM은 관여하지 않습니다.

```
$ api-doctor run -d seoul_library -c examples/connector_partial.py
```

```
✓ execution      후보가 4건을 반환했습니다.
✓ fields         4건에서 필수 필드가 보존되었습니다.
✓ values         2개 값 규칙을 만족합니다.
✗ completeness  누락 1건; 건수 4 != 기대 5
```

네 개의 신뢰 영역

Zone U CLI, 입력 검사, 보고서 LLM 없음	Zone T 레지스트리, 고정 검증기, 데이터 브로커, 도구 게이트웨이, 종료 게이트 LLM 없음	Zone A main + 전문가 4명 LLM 있음	Zone S 후보 코드 실행 네트워크 차단 LLM 없음
--	---	--	--

Zone A는 Zone T의 검증기와 기대값에 **코드 수준에서 닿을 수 없습니다**. 프롬프트로 부탁한 것이 아니라 import 경계로 막았고, CI가 AST를 파싱해서 매번 검사합니다.

```
# tests/test_import_boundaries.py    (전 7건 중 4건)
FORBIDDEN = [
    ("verify", ("agents","tools","model"), "고정 검증기는 모델 판단과 분리된다"),
    ("sandbox", ("agents","model","verify"), "Zone S 는 Zone A 를 모른다"),
    ("agents", ("evaluation",), "에이전트가 평가용 비공개 기대값에 닿으면 안 된다"),
    ("runtime", ("evaluation",), "런타임이 평가 세트를 알면 안 된다"),
]
```

2. 아키텍처




그림 1. 신뢰 영역과 경계를 넘는 것들. 모델이 도는 영역(A)은 검증기, 기대값, 네트워크, 파일시스템 중 어디에도 닿지 않습니다. 경계를 넘는 것은 전부 Zone T가 조립한 구조화 데이터뿐입니다.

에이전트 팀

main / recovery_lead	위임과 종료 요청만 한다. 코드를 쓰거나 실행하지 못한다.
└ spec_researcher	공식 명세의 응답 구조, 조회 규칙, 오류 구별
└ runtime_diagnostician	어디서 왜 손실이 생기는지 관측
└ repair_engineer	최소 패치 (이 역할만 코드를 바꾼다)
└ data_auditor	수리자의 설명 없이 독립적으로 손실 조사

권한은 프롬프트에 적힌 부탁이 아니라 실행 컨텍스트에 바인딩된 클로저입니다. 모델이 agent_id를 위조해도 무시됩니다. 위험 도구 누수 없음, 하위 재위임 가능 역할 없음을 실측으로 확인했습니다.

역할	실제 바인딩된 도구
main	get_budget, read_evidence, read_file, request_finish, request_stop, task
spec_researcher	get_budget, read_evidence, search_spec
runtime_diagnostician	get_budget, inspect_code, inspect_trace, read_evidence, run_probe
repair_engineer	get_budget, inspect_code, read_evidence, run_probe, submit_patch
data_auditor	get_budget, inspect_code, inspect_trace, read_evidence, run_probe

3. 실행 흐름




그림 2. 모델을 부르는 구간과 부르지 않는 구간. 입력 검사, 격리 경계 확인, 원본 실행, 고정 검증까지는 모델 호출이 0회입니다. 결함이 확인된 경우에만 복구 루프로 들어갑니다.

쉬운 경우에는 팀을 부르지 않습니다

원본이 이미 계약을 만족하면 verified_unchanged로 끝납니다. 인증이 만료됐거나 제공기관이 죽었으면 needs_user_action으로 끝납니다. 둘 다 모델을 한 번도 부르지 않습니다. 인증이 막힌 응답으로 계약을 검증하는 것은 의미가 없으므로 고정 검증 자체를 건너뛰니다.

격리 실행

후보 코드는 네트워크가 끊긴 컨테이너에서만 돕니다.

```
--network none --read-only --cap-drop ALL --security-opt no-new-privileges
--user 65534:65534 --pids-limit 32 --memory 512m --cpus 1 --tmpfs /tmp
```

경계를 믿지 않고 매번 증명합니다. 실행 직전에 자가검사 5종을 돌리고, 하나라도 차단되지 않으면 후보를 실행하지 않습니다.

자가검사	무엇을 시도하나	결과
network_egress	HTTP 송신, 직접 소켓, DNS 조회	차단
write_outside_workdir	작업 디렉터리 밖 쓰기	차단
read_host_secret	호스트 비밀 읽기, 환경변수 카나리아	차단
process_limit	프로세스 폭증	차단
privilege_escalation	권한 상승	차단

카나리아는 호스트의 docker 프로세스에만 존재하는 환경변수입니다. 컨테이너 안에서 보이면 환경변수가 경계를 넘은 것입니다. API 키는 후보 코드에 {KEY} 자리표시자로만 전달되고, 실제 키는 Zone T의 브로커만 가집니다.

4. 감사자는 왜 설명을 받지 못하나



그림 3. 중립 작업 봉투. 런타임이 감사자에게 봉투를 새로 조립합니다. 수리자의 설명과 main의 대화는 전달되지 않고, 기대값은 어떤 역할도 읽을 수 없습니다.

감사자에게 수리자의 설명을 주면 감사는 그 설명을 검토하는 일이 됩니다. 그러면 설명이 그럴듯할수록 통과합니다. 런타임이 중립 작업 봉투를 새로 조립해서 관측 증거만 넘깁니다. 수리자의 서술도, main의 대화도, 기대값도 넘어가지 않습니다.

그래서 감사자는 믿을 것이 없습니다. **직접 probe를 돌려 관측해야 결론을 낼 수 있습니다.**

독립성은 "다른 모델"이 아닙니다. 감사자도 같은 모델을 씁니다. 독립성은 입력을 다르게 주는 것으로 만들고, 증거 저장소의 visibility 필드가 이를 강제합니다. 같은 모델의 상관된 실수는 여전히 가능하며, 그것은 고정 검증기가 보완합니다. 감사는 검증을 대신하지 않고 보태니다.

5. 종료 게이트



그림 4. 네 단계 판정. 네 조건의 논리곱입니다. 하나라도 어긋나면 승격하지 않습니다.

```

def evaluate(session, *, candidate_hash, final_verdict) -> GateDecision:
    """최종 판정. 순서가 곧 우선순위다."""
    # ① 강제 중단이 있었나      (취소, 예산 소진, 정책 차단)
    # ② 현재 hash 의 고정 검증을 통과했나
    # ③ 현재 hash 에 대한 감사가 완료됐나
    # ④ 계약 관련 미해결 근거가 없나
  
```

main의 종료 요청, 일반 텍스트 종료, 에이전트 예외, 루프 상한이 전부 같은 게이트로 수렴합니다. "끝났다"고 말할 수 있는 경로가 하나뿐입니다.

강제 중단 뒤에는 통과한 검사가 있어도 승격하지 않습니다. 취소나 예산 소진으로 끊긴 실행은 "검증됐다"고 부를 수 없기 때문입니다.

감사 완료의 조건

- 계약의 필수 위험 영역을 probe catalog의 고정 coverage로 전부 덮어야 합니다
- baseline과 다른 probe를 현재 candidate_hash와 snapshot_hash에서 실제로 실행해야 합니다
- 각 영역마다 가설, 불변식, probe_result_id, 결론을 채워야 합니다. 빈 findings는 완료가 아닙니다
- 0건짜리 후보의 공허한 성립은 위험 영역을 덮은 것으로 세지 않습니다

6. 검증

두 종류의 검증을 분리했습니다

	무엇	언제
제품의 고정 검증	registry/*/expected/	수리 중에 결과를 돌려줍니다. 모델이 기준을 바꿀 수 없습니다
평가용 비공개 세트	eval/hidden.json	에이전트에게 숨겼다가 최종 패치 확정 후에만 실행합니다

비공개 세트는 계약의 주 query와 다른 범위를 씁니다. 팀이 그 범위에 맞춰 최적화할 방법이 없습니다. 평가 실패를 같은 작업의 재수리로 돌려보내지도 않습니다.

실측 (2026-09-28)

항목	결과	비고
결함 탐지 평가	18/18	거짓 성공 0건
격리 경계 자가검사	5/5	환경변수 카나리아 포함
테스트	183 통과	구역 간 import 경계는 CI가 AST로 강제

비공개 검증이 잡아낸 진짜 버그

한 케이스가 제품에서는 실패인데 비공개 검사는 통과했습니다. 추적해보니 같은 후보가 세 번 정상 실행된 뒤 **가장 중요한 종료 검증만** 실패하고 있었습니다.

sandbox_run	hash=f509a2b6	returned=5	정상
sandbox_run	hash=f509a2b6	returned=5	정상
sandbox_run	hash=f509a2b6	returned=5	정상
sandbox_run	hash=f509a2b6	returned=None	종료 검증만 실패
브로커 호출: 20 / 20			

원인은 동결된 스냅샷 읽기까지 공식 API 호출 상한에 넣은 것이었습니다. 이것은 **거짓 실패**를 만드는 종류의 버그입니다. 거짓 성공과 달리 조용히 지나가고, 비공개 검사가 없었으면 "복구 실패"로 집계됐을 것입니다. 평가를 만든 이유가 이것입니다.

7. 기술 스택

NVIDIA

항목	내용
모델	nvidia/nemotron-3-super-120b-a12b (reasoning)
폴백	nvidia/nemotron-3-nano-omni-30b-a3b-reasoning
엔드포인트	NVIDIA NIM · integrate.api.nvidia.com/v1 (OpenAI 호환)
발급	build.nvidia.com 무료 등급
프로파일링	NeMo Agent Toolkit 형식의 역할별 구간 리포트

reasoning 모델이라 추론 토큰이 completion_tokens에 함께 잡힙니다. 사소한 JSON 한 줄에도 출력 258토큰이 나갔습니다. 그래서 역할별 출력 상한을 따로 잡았습니다 (수리자 12288, 나머지 3072).

에이전트 하네스

deepagents 0.7.19가 기본입니다. LangChain의 wrap_tool_call 미들웨어 혹에서 task 위임을 가로채 예산과 권한과 중복 위임을 검사합니다. 기본 파일시스템 백엔드가 호스트에 닿지 않는 StateBackend임을 확인하고 FilesystemMiddleware(tools=["read_file"])로 쓰기 도구를 제거했습니다. 자동 요약 미들웨어는 꺾습니다. main의 모델 예산을 몰래 먹고 있었습니다.

그 외

Python 3.12, uv, Typer, Rich, Pydantic, httpx, pytest, Docker

8. 공급자 가용성 대응

무료 등급의 실제 가용성

모델별로 8회씩 측정했습니다.

모델	성공	실패 내역
nemotron-3-super-120b-a12b (주)	1/8	429×4, 503×3
nemotron-3-nano-omni-30b-a3b-reasoning	4/8	503×4
llama-3.1-nemotron-70b-instruct	0/8	404
llama-3.1-nemotron-ultra-253b-v1	0/8	404
llama-3.1-nemotron-51b-instruct	0/8	404

/v1/models에 있다고 부를 수 있는 것이 아닙니다. llama-3.1-nemotron 계열 세 종은 모델 목록에 나오지만 /v1/chat/completions로는 전부 404였습니다.

두 실패를 구분해서 다르게 대응합니다.

코드	정체	대응
429	우리가 너무 빨리 불렀습니다	맞고 물러서는 대신 호출 사이에 최소 간격을 둡니다. Retry-After가 오면 그쪽을 따릅니다
503	공급자 과부하입니다	0.1초 만에 즉시 거절되므로 기다려도 줄지 않습니다. 폴백 모델로 즉시 갈아탑니다

폴백 적용 전 1/8에서 적용 후 10/10이 됐습니다 (주 모델 7회, 폴백 3회). 어떤 모델이 응답했는지는 호출마다 기록합니다. 그러지 않으면 "성공률이 올랐다"는 말이 어느 모델의 성적인지 알 수 없어 측정이 거짓말이 됩니다.

9. 남길 만한 개발 기록

틀린 판단을 지우지 않고 기록으로 남겼습니다.

deepagents를 한 번 잘못 기각했습니다

호스트 파일시스템에 닿는다고 판단해서 배제했는데, 근거 두 개가 다 틀렸습니다. 기본 백엔드는 호스트를 건드리지 않는 `StateBackend`이고, `FilesystemMiddleware(tools=[...])`는 도구를 완전히 제거합니다. `HarnessProfile.excluded_tools`만 시험해보고 내린 결론이었습니다. 문서를 조용히 덮어쓰지 않고 철회 기록으로 남겼습니다.

진단을 한 번 틀렸습니다

역할별 호출 상한이 강제되지 않는 것처럼 보였습니다. 한 역할이 10회, 다른 역할이 15회를 쓴 사건이 남아 있었습니다. 실제로는 그것이 *시도* 수였고 공급자 실패는 환불되므로 과금된 호출은 1회와 4회였습니다. **환불이 있는 원장에서는 사건 수와 과금 수를 섞어 세면 안 됩니다.**

평가가 처음에 엉뚱한 것을 했습니다

결함 탐지를 최종 상태로 판정했는데, 키가 없으면 모든 결함 케이스가 `needs_user_action`으로 끝납니다. "결함을 탐지했는지"가 아니라 "키가 없는지"를 재고 있었습니다. `baseline` 판정으로 바꿨습니다.

제가 만든 격리 시험이 틀렸습니다

호스트 비밀 읽기 시험이 `PermissionError`로 죽어서 실패로 잡혔는데, 사실은 샌드박스가 가정보다 더 엄격했던 것입니다. `Path.exists()`가 `EACCES`를 삼키지 않습니다. "실제로 읽히는가"를 묻도록 고치고 환경변수 카나리아를 추가했습니다.

자동 요약이 예산을 몰래 먹고 있었습니다

deepagents는 기본 스택에 요약 미들웨어를 넣고 `main`의 모델로 요약을 돌립니다. 원장에는 `main` 호출로 잡히지만 용도가 구분되지 않습니다. 위임 2건에 `main` 호출 8회가 나가던 원인이었습니다. 끄자마자 첫 `verified_repaired`에 도달했습니다.